

Relatório — Métodos e Fórmulas para Geração de Dados Sintéticos

(Daniel Costa Santos)

1. Processos de contagem — Distribuição de Poisson

Usado para simular quantas pessoas passam/aparecem em um intervalo de tempo (ex.: contagem por hora).

$$P(X = k) = (\lambda^k \cdot e^{(-\lambda)}) / k!$$

- λ = número médio esperado de pessoas no intervalo
- k = número de pessoas observado (variável simulada)

Uso típico: gerar séries temporais de "quantidade de pessoas por período" com variabilidade realista.

2. Processo de Poisson não-homogêneo (λ variável no tempo)

Quando o fluxo de pessoas muda ao longo do dia (pico de manhã, queda à tarde, etc.):

$$\lambda(t) = \lambda_0 \cdot f(t)$$

onde $f(t)$ é uma função (senoidal, gaussiana, escalonada) que modula a intensidade média conforme o horário t .

Exemplo de $f(t)$ gaussiana (simulando um "pico" de movimento):

$$f(t) = \exp(-(t - \mu)^2 / (2\sigma^2))$$

- μ = horário de pico
- σ = "largura" do pico (quanto tempo dura o movimento intenso)

3. Distribuição Normal (Gaussiana) — atributos contínuos

Para gerar variáveis contínuas simuladas de pessoas (idade, tempo de permanência, distância percorrida):

$$f(x) = (1 / (\sigma\sqrt{2\pi})) \cdot \exp(-(x - \mu)^2 / (2\sigma^2))$$

- μ = média do atributo
- σ = desvio padrão

Uso típico: idade média dos indivíduos, tempo médio de permanência no local, etc.

4. Distribuição Exponencial — tempos entre eventos

Para simular o tempo entre chegadas de pessoas (interarrival time) ou tempo de permanência:

$$f(x) = \lambda \cdot e^{(-\lambda x)}, \quad x \geq 0$$

- λ = taxa de chegada (inverso do tempo médio entre eventos)
- Média = $1/\lambda$

Uso típico: gerar horários de chegada de "pessoas simuladas" um a um, de forma realista (em vez de todas ao mesmo tempo).

5. Lei de Potência / Zipf — frequência de visitas

Para simular que poucas pessoas visitam muitas vezes e muitas visitam poucas vezes (padrão comum em dados de mobilidade humana):

$$P(X = k) \propto k^{-\alpha}$$

- α = expoente da lei de potência (tipicamente entre 1 e 3)
- k = número de visitas/ocorrências

Uso típico: distribuir "número de visitas por pessoa simulada" de forma não uniforme e realista.

6. Cadeias de Markov — padrões de movimento/transição

Para simular deslocamento entre pontos (ex.: de um ponto A para B, C, etc.), usa-se uma matriz de transição:

$$P(X_{t+1} = j \mid X_t = i) = P_{ij}$$

- P_{ij} = probabilidade de ir do estado (local) i para o estado j
- A matriz P deve ter cada linha somando 1

Uso típico: simular trajetos de pessoas entre pontos de interesse.

7. Processos de pontos espaciais (Spatial Point Process)

Para simular onde as pessoas estão distribuídas no espaço (não apenas quando):

- Processo de Poisson espacial (uniforme): pontos distribuídos aleatoriamente com densidade constante λ por unidade de área.
- Processo de Neyman-Scott (em aglomerados/clusters): simula "grupos" de pessoas (ex.: pontos turísticos, filas), com pontos-pai gerando pontos-filho ao redor:

$$\text{Número de clusters} \sim \text{Poisson}(\lambda_{\text{pai}})$$

$$\text{Pontos por cluster} \sim \text{Poisson}(\lambda_{\text{filho}})$$

$$\text{Posição do filho} = \text{posição do pai} + \text{deslocamento} \sim \text{Normal}(0, \sigma^2)$$

Uso típico: simular concentração de pessoas em pontos específicos de um espaço físico, em vez de espalhamento uniforme.

8. Redes Bayesianas — variáveis correlacionadas

Quando há múltiplas variáveis que se influenciam (ex.: idade $\rightarrow$ tipo de atividade $\rightarrow$ tempo de permanência), pode-se definir a distribuição conjunta como produto de condicionais:

$$P(X_1, X_2, \dots, X_n) = \prod P(X_i \mid \text{pais}(X_i))$$

Uso típico: gerar perfis sintéticos de pessoas onde os atributos não são independentes entre si.

9. Simulação de Monte Carlo (framework geral)

Não é uma fórmula única, mas um método: gerar repetidamente amostras aleatórias a partir das distribuições acima (Poisson, Normal, Exponencial etc.) e agregar os resultados para formar o dataset sintético completo.

Estrutura geral:

- Definir distribuições/parâmetros para cada variável.
- Amostrar N vezes.
- Agregar em tabela (dataset sintético).
- Validar contra padrões esperados (médias, variância, formato da distribuição).

10. Modelagem baseada em agentes (Agent-Based Modeling)

Cada "pessoa simulada" é um agente com regras próprias de comportamento (velocidade, destino, tempo de permanência), e o dataset final surge da interação/execução dessas regras ao longo do tempo simulado. Não tem uma fórmula fechada única — combina as distribuições acima (Poisson para chegada, Markov para movimento, Normal para atributos) dentro de um loop de simulação.

11. (Alternativa avançada) Modelos generativos — GANs / VAEs

Para geração de dados sintéticos mais sofisticados e realistas a partir de dados reais existentes (caso haja uma base real para treinar):

- GAN: duas redes competem — gerador (cria dados falsos) e discriminador (tenta distinguir real de falso) — treinadas via:

$$\min_G \max_D E[\log D(x)] + E[\log(1 - D(G(z)))]$$

- VAE: aprende uma distribuição latente e gera novas amostras a partir dela.

Resumo comparativo

Método	O que simula	Complexidade
Poisson	Quantidade de pessoas por intervalo	Baixa
Poisson não-homogêneo	Fluxo variável ao longo do dia	Baixa-média
Normal	Atributos contínuos (idade, etc.)	Baixa
Exponencial	Tempo entre eventos/permanência	Baixa
Lei de potência (Zipf)	Frequência desigual de visitas	Baixa-média
Cadeia de Markov	Movimento entre pontos	Média
Processo de pontos espaciais	Distribuição espacial (clusters)	Média
Rede Bayesiana	Atributos correlacionados	Média-alta
Monte Carlo	Framework geral de simulação	—
Baseado em agentes	Comportamento individual completo	Alta
GAN/VAE	Dados sintéticos realistas a partir de dados reais	Alta