

Geração e Validação de Dados Sintéticos para Digital Twins

Abordagem Baseada em Agentes, Campos de Potencial e Cópulas Arquimedianas

1 Introdução e Fundamentação

A simulação de multidões e a geração de dados sintéticos em ambientes urbanos densos e culturalmente ricos, como o centro histórico do Pelourinho, exigem uma abordagem que vá além da amostragem estática de distribuições de probabilidade isoladas. Para um *Digital Twin* (Gêmeo Digital) operar com precisão, a modelagem deve refletir a natureza dinâmica e interconectada dos fenômenos urbanos locais.

A tese aqui defendida propõe a substituição de geradores de dados baseados puramente em contagem e fluxos macroscópicos por um modelo micro-simulado (Modelagem Baseada em Agentes - ABM). Essa escolha se alinha com as melhores práticas de análise exploratória e modelagem estatística avançada, garantindo que os dados sintéticos gerados preservem as intrincadas correlações não-lineares observadas na realidade, servindo de base sólida para modelos de aprendizado de máquina posteriores.

2 Dinâmica Espaço-Temporal: O Modelo de Agentes

Ao invés de determinar "quantas pessoas estão no local" de forma *top-down*, a abordagem modela o indivíduo (agente). A posição $\mathbf{r}_i(t) = (x_i(t), y_i(t))$ do agente i evolui conforme um sistema de equações diferenciais estocásticas, influenciado pelo ambiente ao seu redor.

2.1 Campos de Potencial e Forças Sociais

O ambiente urbano é mapeado através de campos atratores (Pontos de Interesse - POIs, como praças centrais, museus e áreas comerciais) e forças repulsivas (evitação de colisão com outros pedestres ou restrições arquitetônicas do local).

A força de atração exercida por um POI j localizado em $\mathbf{p}_j$ é dada pelo gradiente negativo de seu potencial:

$$\mathbf{F}_{ij}^{\text{attr}} = -\nabla U_j(\mathbf{r}_i) = \alpha_j \cdot \frac{\mathbf{p}_j - \mathbf{r}_i}{\|\mathbf{p}_j - \mathbf{r}_i\|_2^2 + \epsilon} \quad (1)$$

Onde α_j representa o "peso" de atratividade do local (variável de acordo com o horário do dia) e ϵ é uma constante de regularização para evitar singularidades matemáticas nas adjacências do alvo.

A repulsão interpessoal para evitar sobreposição entre o agente i e o agente k segue um decaimento exponencial, simulando a necessidade de espaço pessoal:

$$\mathbf{F}_{ik}^{\text{rep}} = \beta \cdot \exp\left(-\frac{\|\mathbf{r}_i - \mathbf{r}_k\|}{\sigma_r}\right) \hat{\mathbf{r}}_{ik} \quad (2)$$

2.2 Equação de Langevin para o Movimento

A trajetória final de cada agente é computada resolvendo a Equação de Langevin, que combina a intenção determinística de movimento com variações estocásticas (ruído):

$$d\mathbf{r}_i(t) = \left(\sum_j \mathbf{F}_{ij}^{\text{attr}} + \sum_k \mathbf{F}_{ik}^{\text{rep}} \right) dt + \sqrt{2D} d\mathbf{W}_i(t) \quad (3)$$

Nesta formulação de cálculo estocástico, $d\mathbf{W}_i(t)$ é o processo de Wiener (movimento browniano). Essa adição é fundamental para introduzir o fator de imprevisibilidade

e exploração inerente ao comportamento humano de turistas e residentes, sendo D o coeficiente de difusão escalar.

3 Geração de Perfil: Cópulas Arquimedianas

A geração de atributos dos agentes (idade, tempo de permanência, propensão a interações) frequentemente falha quando tratada através de distribuições independentes. Para capturar a dependência multivariada — uma exigência crítica em Ciência de Dados para evitar o viés da independência — aplicamos o conceito estatístico de Cópulas, que isola a estrutura de dependência das distribuições marginais.

A Cópula de Frank, pertencente à família arquimediana, permite modelar a distribuição conjunta $C(u, v)$ de variáveis contínuas:

$$C(u, v) = -\frac{1}{\theta} \ln \left(1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1} \right) \quad (4)$$

Onde $u = F_1(x_1)$ e $v = F_2(x_2)$ são as funções de distribuição acumulada (CDFs) marginais dos atributos. O parâmetro θ ($\theta \neq 0$) modula a força e a direção da dependência, permitindo simular cenários complexos (ex: correlação negativa entre idade avançada e velocidade de caminhada) sem instanciar pesadas Redes Bayesianas.

4 Protocolo de Validação Matemática

A maior barreira na síntese de dados em projetos de engenharia de software e IA é atestar a sua aderência ao domínio original. A solução técnica proposta emprega testes não paramétricos rigorosos, cruzando o *dataset* sintético contra amostras observacionais.

4.1 Validação Espacial: Teste KS Bidimensional

Para garantir que os agentes sintéticos formem *clusters* geográficos realistas, utiliza-se a generalização bidimensional do teste de Kolmogorov-Smirnov. Ele mensura a suprema divergência entre a distribuição de densidade espacial sintética e a empírica:

$$D_{2D} = \max_{(x,y)} |F_{\text{sintetico}}(x, y) - F_{\text{real}}(x, y)| \quad (5)$$

Os hiperparâmetros de atratividade α do modelo de movimento são iterativamente calibrados em um loop de otimização até que D_{2D} satisfaça o limiar crítico de aceitação do projeto.

4.2 Validação de Fluxos: Divergência de Kullback-Leibler (KL)

Para as métricas de séries temporais (fluxo volumétrico de pessoas por hora), avaliamos o ganho de informação relativo ou entropia relativa entre a densidade teórica esperada $P(t)$ e a densidade gerada na simulação $Q(t)$:

$$D_{KL}(P \parallel Q) = \sum_{t \in T} P(t) \log \left(\frac{P(t)}{Q(t)} \right) \quad (6)$$

A minimização do escore D_{KL} assegura que a agregação das movimentações estocásticas microscópicas produza o perfil macroscópico desejado para o *Twin*.

5 Conclusão da Tese

A arquitetura formalizada neste documento garante um *pipeline* ponta a ponta robusto para o ecossistema do Digital Twin. A interseção matemática entre a cinética de *Langevin* (para movimentação baseada no ambiente local), a correlação de *Cópulas* (para atribuição de características coerentes) e a verificação estatística estrita (via *KS* e *KL*) fornece uma massa de dados sintéticos inquestionável sob a ótica analítica, ideal para alimentar painéis, modelos de simulação e análises de impacto urbano complexas.